

REGRESIÓN LOGÍSTICA

- Se estableció como una técnica en el campo de la estadística a finales de la década de 1940 y la década de 1950
- Técnica de clasificación binaria
 - A pesar de llamarse “regresión”
 - Es un tipo de regresión lineal, pero en lugar de predecir un valor continuo, predice una probabilidad
 - Útil para modelar datos que tienen dos categorías
 - Para ser aplicada a muticlase, estrategia “uno contra todos” o “uno contra uno”

REGRESIÓN LOGÍSTICA

- En la regresión logística, el objetivo es modelar la relación entre las características y la probabilidad de pertenencia a una categoría
 - Por ejemplo, predecir si un email es spam o no spam
 - Determinar la existencia o ausencia de relación entre una o más variables independientes y una variable dependiente dicotómica
 - Es decir, que sólo admite dos categorías que definen opciones o características mutuamente excluyentes u opuestas
 - Estimar o predecir la probabilidad de pertenencia a esa categoría en función de los valores que adoptan las variables independientes

REGRESIÓN LOGÍSTICA

- Si p es la probabilidad de pertenencia a la clase 1
 - $1-p$ es la probabilidad de pertenencia a la clase 0

$$p(y = 0|x) = 1 - p(y = 1|x)$$

- El *odds* (razón de probabilidades) es un concepto en estadística que mide la relación entre dos probabilidades
 - El cociente de la probabilidad de pertenecer a una clase y la probabilidad de no pertenecer
 - Es decir, el cociente del número de casos que pertenecen entre el número de casos que no pertenecen

$$odds = \frac{p}{1 - p}$$

REGRESIÓN LOGÍSTICA


- El *odds* se utiliza comúnmente en problemas de probabilidad y en el análisis de datos
 - Es una manera de expresar cuántas veces más probable es que ocurra un evento en comparación con que no ocurra
 - Proporción entre algo que ocurre y algo que no ocurre
 - Probabilidad: La probabilidad es la relación entre algo que ocurre y todo lo que podría ocurrir.
 - También llamado:
 - Razón de momios
 - Razón de oportunidades
 - Razón de probabilidades

REGRESIÓN LOGÍSTICA

- El *odds* toma un valor no negativo
 - Un *odds* de 1 indica que las probabilidades de que ocurra o no ocurra el evento son iguales
 - Un *odds* mayor que 1 indica que el evento es más probable que ocurra
 - Un *odds* menor que 1 indica que el evento es menos probable que ocurra
- El *odds* es especialmente útil cuando se comparan dos resultados, por ejemplo:
 - Apuestas deportivas, estudios médicos, análisis epidemiológicos para evaluar la relación entre exposición y enfermedad, etc.
 - En general, **clasificación binaria**

REGRESIÓN LOGÍSTICA


- Ejemplo:
 - Probabilidad de padecer enfermedad coronaria en función de la edad:



- Relación no lineal, sino con una forma sigmoidea (distribución logística)

REGRESIÓN LOGÍSTICA

- Ejemplo:



REGRESIÓN LOGÍSTICA

- El *log-odds* es el resultado de aplicar un logaritmo natural al *odds*
 - Representa la transformación logarítmica de la relación entre dos probabilidades
 - Logaritmo de la razón de probabilidades


$$\log - odds = \log(odds) = \log\left(\frac{p}{1-p}\right)$$

- A esta función se llama $\text{logit}(p)$

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right) = z$$

REGRESIÓN LOGÍSTICA

- El *log-odds* toma valores en el rango de $-\infty$ a $+\infty$
 - Si $p=0.5 \rightarrow \log\text{-odds}=0$
 - $p=0.5 \rightarrow$ las probabilidades de que ocurra o no ocurra un evento son iguales
 - p se acerca a 1 \rightarrow el *log-odds* se acerca a ∞
 - p se acerca a 0 \rightarrow el *log-odds* se acerca a $-\infty$



- Además, la función logit es el negativo de la derivada de la función de entropía binaria

REGRESIÓN LOGÍSTICA

- A partir de esta expresión, se puede despejar p:

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right) = z \quad \Rightarrow \quad \frac{p}{1-p} = e^z \quad \Rightarrow \quad p = (1-p)e^z \quad \Rightarrow$$

$$\Rightarrow (1 + e^z)p = e^z \quad \Rightarrow \quad p = \frac{e^z}{1 + e^z} = \frac{1}{1 + e^{-z}}$$

- Por lo tanto, la probabilidad de un caso positivo se expresa en función de una función **logística**
 - También conocida como función **sigmoide**
- La regresión logística utiliza la función logística para transformar el *log-odds* en una probabilidad en el rango de 0 a 1
 - Esto permite la modelización y la predicción en problemas de clasificación

REGRESIÓN LOGÍSTICA

- Por tanto, se puede calcular p en función del *log-odds*
- Este valor del *log-odds* será la salida de un modelo cuyas entradas serán las variables independientes
- En regresión logística este será un modelo lineal
 - Es decir, z será una combinación lineal de las características de entrada

$$z = \text{logit}(p) = b_0 + \sum b_i x_i$$

REGRESIÓN LOGÍSTICA

- ¿Por qué utilizar un modelo lineal?
 - Simplicidad en la modelización:
 - La elección de una relación lineal permite una formulación matemática más simple y computacionalmente eficiente del modelo
 - Los métodos de optimización y ajuste de parámetros también se vuelven más manejables
 - Interpretación:
 - Los cambios en las características se traducen en cambios proporcionales en los *log-odds*
 - Esto es útil para entender cómo las características afectan la probabilidad de pertenencia a una categoría.

REGRESIÓN LOGÍSTICA


- ¿Por qué utilizar un modelo lineal?
 - Facilita la regularización:
 - Al expresar la relación entre las características y el resultado en forma lineal, es más sencillo aplicar técnicas de regularización como L1 (*Lasso*) o L2 (*Ridge*), que penalizan los coeficientes grandes
 - Esto puede ayudar a prevenir el sobreajuste y mejorar la generalización del modelo
 - Comprobada efectividad empírica:
 - A lo largo de la historia de la estadística y el aprendizaje automático, se ha demostrado que una relación lineal en un espacio logarítmico es una representación efectiva para capturar las relaciones entre características y probabilidades

REGRESIÓN LOGÍSTICA

- La regresión logística combina la función logística con una combinación lineal de las características:

- Función a utilizar: logística
 - También llamada sigmoide

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$



- Muy usada en redes de neuronas artificiales
- Valores altos de $z \rightarrow f(z)=1$
- Valores bajos de $z \rightarrow f(z)=0$
- Función continua, y acotada entre 0 y 1
- z será la combinación lineal de los atributos de entrada x_i

REGRESIÓN LOGÍSTICA


- La regresión logística combina la función logística con una combinación lineal de las características:
 - Modelo de Probabilidad:
 - A través de la función logística (sigmoide), el *log-odds* se transforma en una probabilidad p :

$$p = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{-\text{logit}(p)}} = \frac{1}{1 + e^{-(b_0 + \sum b_i x_i)}}$$

- Valor entre 0 y 1
- Esta es la salida del modelo de regresión logística

REGRESIÓN LOGÍSTICA

- La regresión logística combina la función logística con una combinación lineal de las características:




- ¿Se podría utilizar la regresión lineal para el cálculo de probabilidades?


REGRESIÓN LOGÍSTICA

- Regresión lineal vs. Regresión logística

Linear Regression

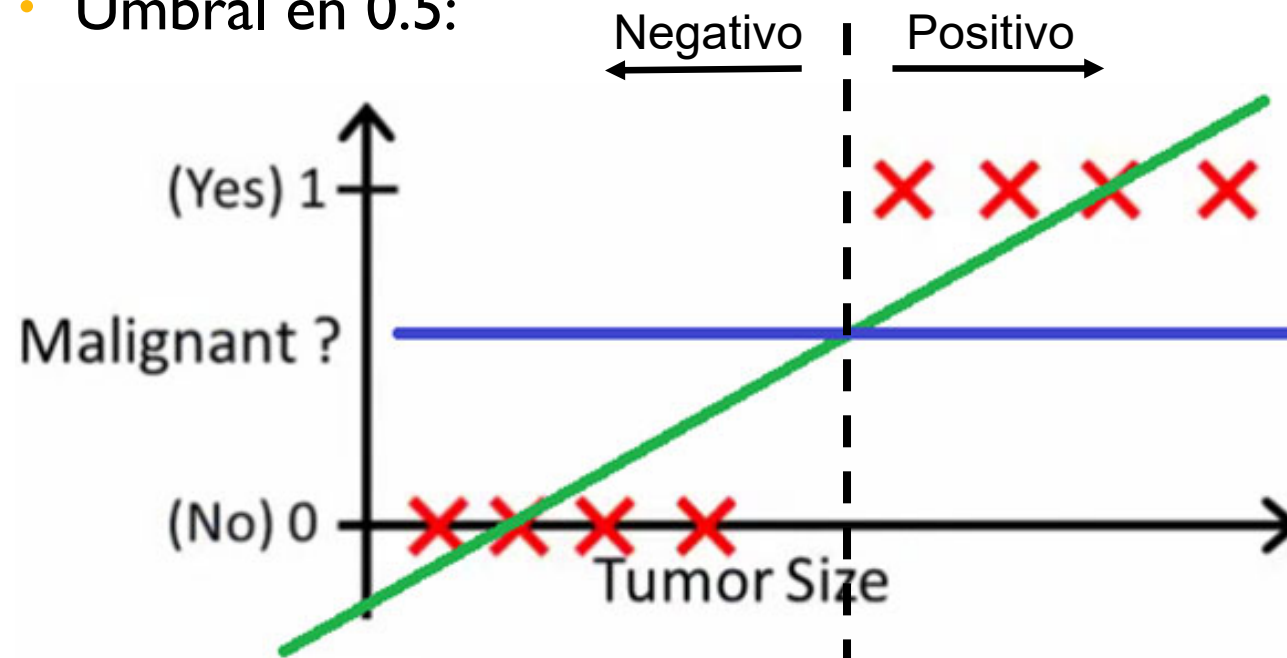


Logistic Regression




REGRESIÓN LOGÍSTICA

- Por qué no usar únicamente regresión lineal como modelo en problemas de clasificación
 - Ejemplo: Clasificación de tumores en malignos (positivo) o benignos (negativo) según el tamaño
 - Umbral en 0.5:



REGRESIÓN LOGÍSTICA

- Por qué no usar únicamente regresión lineal como modelo en problemas de clasificación
 - Ejemplo: Clasificación de tumores en malignos (positivo) o benignos (negativo) según el tamaño
 - Si el conjunto de datos tiene un valor atípico
 - La línea de mejor ajuste en la regresión lineal se desplaza para ajustarse a ese punto



REGRESIÓN LOGÍSTICA

- Por qué no usar únicamente regresión lineal como modelo en problemas de clasificación
 - Ejemplo: Clasificación de tumores en malignos (positivo) o benignos (negativo) según el tamaño
 - Si el conjunto de datos tiene un valor atípico
 - La línea de mejor ajuste en la regresión lineal se desplaza para ajustarse a ese punto
 - La línea azul: umbral antiguo
 - Línea amarilla: nuevo umbral, en este caso podría ser de 0.2
 - Sólo bajando el umbral dará resultados correctos
 - Por lo tanto, la regresión lineal es sensible a los valores atípicos

REGRESIÓN LOGÍSTICA

- Por qué no usar únicamente regresión lineal como modelo en problemas de clasificación
 - Además, un modelo de regresión lineal devuelve valores que no están acotados entre 0 y 1


REGRESIÓN LOGÍSTICA

- Perceptrón vs. Regresión logística

- Regresión logística:

$$p = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{-\text{logit}(p)}} = \frac{1}{1 + e^{-(b_0 + \sum b_i x_i)}}$$

- Perceptrón con función de activación sigmoide:



$$p = \sigma \left(b_0 + \sum b_i x_i \right) = \frac{1}{1 + e^{-(b_0 + \sum b_i x_i)}}$$

REGRESIÓN LOGÍSTICA

- Entrenamiento

- El objetivo del entrenamiento es encontrar los valores óptimos de los coeficientes b_0, b_1, b_2, \dots que minimicen el error de predicción
 - Es decir, que maximicen la probabilidad de que los datos observados sean generados por el modelo
- Se utiliza la técnica de máxima verosimilitud para ajustar los coeficientes

REGRESIÓN LOGÍSTICA

- Entrenamiento

- En teoría de probabilidad y estadística, la distribución Bernoulli (o distribución dicotómica) es una distribución de probabilidad discreta, donde el valor 1 (éxito) ocurre con la probabilidad p y el valor 0 (fracaso) con la probabilidad $1-p$

- La función de probabilidad es

$$p(Y = y) = p^y(1 - p)^{1-y} \quad y \in \{0,1\}$$

- Es decir

$$p(Y = y) = \begin{cases} p & y = 1 \\ 1 - p & y = 0 \end{cases}$$

REGRESIÓN LOGÍSTICA

- Entrenamiento

- Por lo tanto, con la función sigmoide, para una observación y :

$$p(Y = y|X = x) = p^y (1 - p)^{1-y}$$

- Para n observaciones:

- *Likelihood*

$$L = \prod p^y (1 - p)^{1-y}$$

- Se desea maximizar esta expresión

con

$$p = \sigma(z) = \frac{1}{1 - e^{-z}} = \frac{1}{1 - e^{-(b_0 + \sum b_i x_i)}}$$

REGRESIÓN LOGÍSTICA

- Entrenamiento

- Se toma el logaritmo en ambos lados:

$$LL = \log(L) = \sum [y \cdot \log(p) + (1 - y) \cdot \log(1 - p)]$$

- *Log-likelihood*
- Se maximiza $\log(L) \rightarrow$ se maximiza L
- Para maximizar esta función, se aplicaría el ascenso de gradiente
 - En su lugar, se aplica el descenso de gradiente del negativo de esa función
 - Es decir, $\max(\log(x)) = \min(-\log(x))$
 - Maximización se transforma en minimización
 - El negativo de esta función es la función de coste


REGRESIÓN LOGÍSTICA

- Entrenamiento

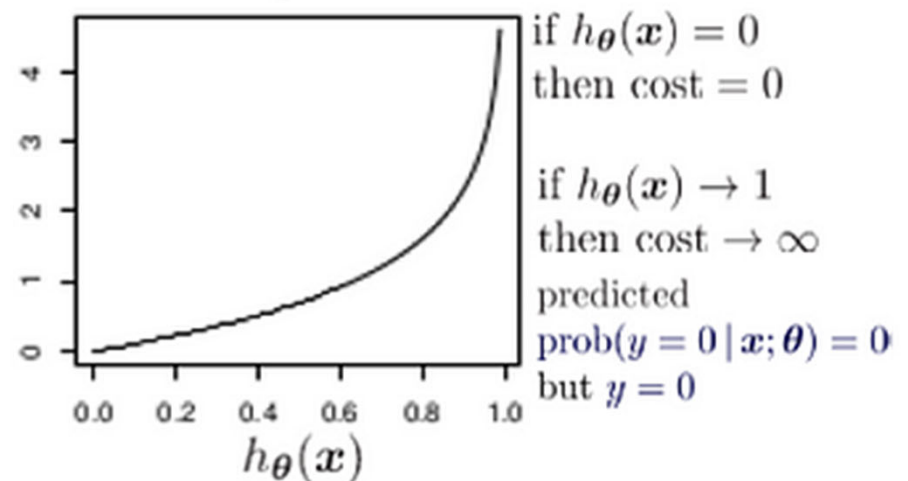
- Por tanto, la función de pérdida es:

$$\text{cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$

if $y = 1$




if $y = 0$



- $h_{\theta}(x) = \sigma(x)$: predicción
- Θ : conjunto de coeficientes (b_i)

REGRESIÓN LOGÍSTICA

- Entrenamiento
 - Si se combinan ambos gráficos, se obtiene una función con un único mínimo:



REGRESIÓN LOGÍSTICA

- Entrenamiento

- Si se combinan ambos gráficos, se obtiene una función con un único mínimo:

- Línea roja: clase positiva ($y=1$)

- Si la probabilidad predicha se aproxima a 1, la pérdida será menor

- Si la probabilidad se acerca a 0, la función de pérdida alcanzará el infinito

- Línea negra: clase negativa 0 ($y=0$)

- Si la probabilidad predicha es cercana a 0, la pérdida será menor

- Si la probabilidad se aproxima a 1 entonces la función de pérdida alcanza el infinito

REGRESIÓN LOGÍSTICA

- Entrenamiento

- Esta función de coste también se denomina *log loss*
 - Pérdida logarítmica
- Garantiza que, a medida que se maximiza la probabilidad de la respuesta correcta, se minimiza la probabilidad de la respuesta incorrecta
 - Por tanto, cuanto menor sea el valor de esta función de coste, mayor será la precisión

REGRESIÓN LOGÍSTICA

- Entrenamiento


- ¿Por qué no se usa la función de coste de regresión lineal?

- Regresión lineal: usa error cuadrático medio

- Se deriva del estimador de máxima verosimilitud
- Tiene un único mínimo

- Si se usa, habrá mínimos locales

- Función no convexa



REGRESIÓN LOGÍSTICA

- Entrenamiento

- Por tanto, se utiliza una función de coste diferente para regresión logística
 - Llamada *log loss*
 - También se deriva del método de estimación de máxima verosimilitud

$$\text{logloss} = \frac{1}{N} \sum_{i=1}^N -[y_i \cdot \log(p_i) + (1 - y_i) \cdot \log(1 - p_i)]$$


REGRESIÓN LOGÍSTICA

- Entrenamiento

- El descenso de gradiente cambia el valor de los coeficientes de tal manera que siempre converge al punto mínimo
 - Es decir, el objetivo es encontrar los coeficientes óptimos que minimizan la función de pérdida del modelo
- Es un método iterativo que encuentra el mínimo de una función calculando la pendiente en un punto y luego moviéndose **en la dirección opuesta**

REGRESIÓN LOGÍSTICA

- Entrenamiento
 - Descenso de gradiente:



REGRESIÓN LOGÍSTICA

- Entrenamiento

- Descenso de gradiente:

Minimizar el negativo de LL

$$b_i(t+1) = b_i(t) - \alpha \frac{\partial(-LL)}{\partial b_i} = b_i(t) + \alpha \frac{\partial LL}{\partial b_i}$$

Necesario moverse en el sentido contrario del gradiente

- Derivada: regla de la cadena:

$$\frac{\partial LL}{\partial b_i} = \frac{\partial LL}{\partial p} \frac{\partial p}{\partial b_i} = \frac{\partial LL}{\partial p} \frac{\partial p}{\partial z} \frac{\partial z}{\partial b_i}$$

con

$$p = \sigma(z) \quad z = b_0 + \sum b_i x_i$$

REGRESIÓN LOGÍSTICA

- Entrenamiento
 - Cálculo de cada una de esas derivadas parciales:

$$\frac{\partial LL}{\partial b_i} = \boxed{\frac{\partial LL}{\partial p}} \frac{\partial p}{\partial z} \frac{\partial z}{\partial b_i}$$

$$LL = \sum [y \cdot \log(p) + (1 - y) \cdot \log(1 - p)] \Rightarrow \frac{\partial LL}{\partial p} = \frac{y}{p} - \frac{1 - y}{1 - p}$$

REGRESIÓN LOGÍSTICA

- Entrenamiento

- Cálculo de cada una de esas derivadas parciales:

$$\frac{\partial LL}{\partial b_i} = \frac{\partial LL}{\partial p} \left[\frac{\partial p}{\partial z} \right] \frac{\partial z}{\partial b_i}$$

$$p = \sigma(z)$$

$$\begin{aligned} \frac{dp}{dz} &= \frac{d\sigma}{dz} = \frac{d}{dz} \left(\frac{1}{1 + e^{-z}} \right) = \frac{-e^{-z}}{(1 + e^{-z})^2} = \frac{1}{1 + e^{-z}} \frac{e^{-z}}{1 + e^{-z}} \\ &= \frac{1}{1 + e^{-z}} \left(1 - \frac{e^{-z}}{1 + e^{-z}} \right) = \sigma(z)(1 - \sigma(z)) = p(1 - p) \end{aligned}$$

REGRESIÓN LOGÍSTICA

- Entrenamiento
 - Cálculo de cada una de esas derivadas parciales:

$$\frac{\partial LL}{\partial b_i} = \frac{\partial LL}{\partial p} \frac{\partial p}{\partial z} \boxed{\frac{\partial z}{\partial b_i}}$$

$$z = b_0 + \sum b_i x_i \quad \Rightarrow \quad \frac{\partial z}{\partial b_i} = \frac{\partial}{\partial b_i} \left(b_0 + \sum b_i x_i \right) = x_i$$

REGRESIÓN LOGÍSTICA

- Entrenamiento

- Uniendo las tres derivadas parciales:

$$\frac{\partial LL}{\partial b_i} = \frac{\partial LL}{\partial p} \frac{\partial p}{\partial z} \frac{\partial z}{\partial b_i} =$$

$$\frac{\partial LL}{\partial p} = \frac{y}{p} - \frac{1-y}{1-p} \quad \frac{dp}{dz} = p(1-p) \quad \frac{\partial z}{\partial b_i} = x_i$$

$$= \left[\frac{y}{p} - \frac{1-y}{1-p} \right] (p(1-p))x_i =$$

$$= (y(1-p) - (1-y)p)x_i = (y-p)x_i$$

REGRESIÓN LOGÍSTICA

- Entrenamiento

- Por lo tanto, la regla de modificación de b_i es:

$$\left. \begin{aligned} b_i(t+1) &= b_i(t) + \alpha \frac{\partial LL}{\partial b_i} \\ \frac{\partial LL}{\partial b_i} &= (y - p)x_i \end{aligned} \right\} b_i(t+1) = b_i(t) + \alpha(y - p)x_i$$

REGRESIÓN LOGÍSTICA

- Entrenamiento

- Comparando esta expresión con la Regla Delta:

$$b_i(t + 1) = b_i(t) + \alpha(y - p)x_i$$

$$w_j(t + 1) = w_j(t) + \mu(d - y)x_j$$


- Expresiones idénticas
 - Partiendo de funciones de coste distintas

REGRESIÓN LOGÍSTICA

- Entrenamiento

- Descenso de gradiente:

- α : tasa de aprendizaje
 - Mismo comportamiento que en la Regla Delta



REGRESIÓN LOGÍSTICA

- Función de pérdida vs. Función de coste
 - *Loss function vs. Cost function*
 - Muchos autores usan ambos términos como sinónimos
- Muchas técnicas de AA se basan en una función de pérdida/coste que minimizar
 - Por ejemplo: Funciones de coste de RR.NN.AA.
 - Regresión: Error cuadrático medio
 - Clasificación: entropía cruzada

REGRESIÓN LOGÍSTICA

- Función de pérdida vs. Función de coste
 - La función de pérdida (o error) es para un ejemplo
 - Es un vector con un valor por cada ejemplo
 - La función de coste es una medida con respecto a todo el conjunto de entrenamiento
 - O el lote (*batch*) utilizado para entrenar
 - Es un valor único, no un vector
 - Evalúa lo bien que lo ha hecho el modelo en su conjunto.

REGRESIÓN LOGÍSTICA

- Función de pérdida vs. Función de coste
 - Por tanto, la formulación de la función de coste se basa en la función de pérdida
 - Comúnmente, la suma o el promedio de la función de pérdida
 - Además, la función de coste puede contener términos de **regularización** además de la función de pérdida
 - Para evitar el sobreajuste

REGRESIÓN LOGÍSTICA

- Regularización
 - Evitar el sobreajuste
 - Técnicas comunes en Regresión Logística:
 - Regularización L1 (*Lasso*)
 - Regularización L2 (*Ridge*)
 - Provenientes de la regresión lineal
 - No son propias de regresión logística
 - Es común utilizarlas en otras técnicas
 - Por ejemplo, muy utilizadas en RR.NN.AA.

REGRESIÓN LOGÍSTICA

- Regularización

- Regularización L1 (*Lasso*) y L2 (*Ridge*)

- Idea principal:

- A lo largo del proceso de entrenamiento es habitual que ciertos parámetros tomen valores muy altos para ajustarse a ejemplos concretos del conjunto de entrenamiento
 - Es decir, particulariza en esos ejemplos
 - La presencia de valores grandes suele provocar que el modelo produzca grandes variaciones en la salida para pequeñas variaciones en la entrada
 - Como resultado, los valores grandes suelen tener un efecto adverso en la capacidad de generalización de una red
 - Los valores altos en parámetros suelen ser característicos de un modelo sobreajustado
 - Mantener los valores bajos añadiendo una penalización al *loss*

REGRESIÓN LOGÍSTICA

- Regularización
 - Regularización L1 (*Lasso*)
 - Lasso es la abreviatura de *Least Absolute Shrinkage and Selection Operator*
 - Se utiliza tanto para la regularización como para la selección de características
 - Esta técnica agrega a la función de coste un término de penalización que es proporcional al valor absoluto de los coeficientes (norma L_1)

REGRESIÓN LOGÍSTICA

- Regularización
 - Regularización L1 (*Lasso*)
 - Función de coste para regresión lineal:

$$L = \sum (y_i - \hat{y}_i)^2 = \sum \underbrace{\left(y_i - \sum b_j x_j \right)^2}_{\text{Función de pérdida}} \quad \Rightarrow \quad L = \underbrace{\sum \left(y_i - \sum b_j x_j \right)^2}_{\text{Función de pérdida}} + \underbrace{\lambda \sum |b_j|}_{\text{Regularización}}$$

REGRESIÓN LOGÍSTICA

- Regularización

- Regularización L1 (*Lasso*)

- Función de coste para regresión lineal:

$$L = \sum (y_i - \hat{y}_i)^2 = \sum \left(y_i - \sum b_j x_j \right)^2 \quad \Rightarrow \quad L = \sum \left(y_i - \sum b_j x_j \right)^2 + \lambda \sum |b_j|$$

- λ es el término de penalización que denota la cantidad de contracción (o restricción) que se implementará en la ecuación.
 - λ puede ser cualquier número de valor real entre cero e infinito
 - Cuanto mayor sea el valor, más agresiva será la penalización
 - Un valor mayor penaliza la función de optimización
 - Con $\lambda=0$, se tiene el equivalente del modelo de regresión lineal de la ecuación

REGRESIÓN LOGÍSTICA

- Regularización

- Regularización LI (*Lasso*)

- Debido a que los coeficientes se “encogen”, algunos tomarán un valor de 0
 - LI tiende a forzar que algunos coeficientes se vuelvan igual a 0
 - Esto equivale a eliminar las características correspondientes
 - Es decir, esta técnica permite realizar **selección automática de características**
 - Además, esto conlleva una simplificación del modelo
 - Más sencillo → menos sobreajuste → mayor generalización
 - Es decir, la regularización *lasso* reduce los coeficientes y ayuda a reducir la complejidad del modelo

REGRESIÓN LOGÍSTICA

- Regularización

- Regularización L2 (*Ridge*)

- Similar a L1, se añade una restricción a los coeficientes mediante la introducción de un factor de penalización
 - En este caso, la penalización es la suma del cuadrado de los coeficientes
 - Función de coste para regresión lineal:

$$L = \sum (y_i - \hat{y}_i)^2 = \sum \left(y_i - \sum b_j x_j \right)^2 \Rightarrow L = \sum \left(y_i - \sum b_j x_j \right)^2 + \lambda \sum b_j^2$$

- Ridge reduce la magnitud de los coeficientes sin necesariamente llevarlos a cero

REGRESIÓN LOGÍSTICA


- Regularización
 - Regularización L2 (*Ridge*)
 - A diferencia de L1, *Ridge* no tiende a anular coeficientes
 - **No permite realizar selección automática de características**
 - En lugar de ello reduce su magnitud de manera uniforme
 - Ayuda a evitar que los coeficientes se vuelvan demasiado grandes y **aporta estabilidad al modelo**
 - En redes de neuronas, este tipo de regularización también se llama decaimiento de pesos (*weight decay*)

REGRESIÓN LOGÍSTICA

- Regularización
 - Regularización L1 (*Lasso*) y L2 (*Ridge*)
 - Si un modelo de regresión lineal utiliza la técnica de regularización L1, se denomina **regresión lasso**
 - Si un modelo de regresión lineal utiliza la técnica de regularización L2, se denomina **regresión ridge**

REGRESIÓN LOGÍSTICA

- Regularización
 - Regularización L1 (*Lasso*) y L2 (*Ridge*)



$$SS_{residuals} = \sum_{i=1}^N (\hat{y}_i - y_i)^2$$

Model Prediction \hat{y}_i (indicated by a red arrow pointing to the predicted value in the equation)

Observed Result y_i (indicated by a red arrow pointing to the observed value in the equation)

Ridge regression
(or "L2 regularization") minimizes:

$$RSS + \alpha \sum_{j=1}^p \beta_j^2$$

$$RSS + \alpha \sum_{j=1}^p |\beta_j|$$

Lasso regression
(or "L1 regularization") minimizes:


p is the number of features

β_j is a model coefficient


α is a tuning parameter: Increasing the α penalizes the coefficients and thus shrinks them.

REGRESIÓN LOGÍSTICA

- Regularización
 - Regularización L1 (*Lasso*) y L2 (*Ridge*)




Lasso Regression



Ridge Regression

REGRESIÓN LOGÍSTICA

- Regularización
 - Regularización L1 (*Lasso*) y L2 (*Ridge*)



REGRESIÓN LOGÍSTICA

- Regularización

- Regularización L1 (*Lasso*) y L2 (*Ridge*)

- Contornos elípticos (rojos): funciones de coste
 - Una elipse para un valor de λ
 - λ cercano a 0: elipse menor
 - $\lambda=0$: punto equivalente a regresión lineal
 - λ alto: elipse mayor
- Rombo, círculo: región restringida de cada modelo
 - La penalización hace que la elipse no pueda estar en el interior
- Ambos métodos determinan los coeficientes encontrando el primer punto en el que los contornos elípticos chocan con la región de restricciones

REGRESIÓN LOGÍSTICA

- Regularización
 - Regularización L1 (*Lasso*) y L2 (*Ridge*)
 - La relajación de las restricciones introducidas por el factor de penalización conduce a un aumento de la región restringida
 - Rombo en *Lasso*, círculo en *Ridge*
 - Es decir, disminuyendo λ
 - Si se disminuyendo λ , se llegará al centro de la elipse
 - En este punto, los resultados tanto de los modelos lasso como ridge son similares a los de un modelo de regresión lineal

REGRESIÓN LOGÍSTICA

- Regularización
 - Regularización L1 (*Lasso*) y L2 (*Ridge*)
 - Regresión *lasso*: la región con restricciones tiene una forma de diamante
 - Por tanto, cada vez que interseca con una región elíptica, al menos uno de los coeficientes se convierte en cero
 - Es decir, al menos una de las características se anulará
 - Se multiplicará por 0
 - Regresión *ridge*: forma circular
 - Por tanto, esto no ocurre
 - Es decir, los valores pueden reducirse cerca de cero, pero nunca ser iguales a cero
 - Por lo tanto, **no se puede utilizar para hacer una selección de características**

REGRESIÓN LOGÍSTICA

- Regularización
 - Otras técnicas de regularización:
 - Elastic Net
 - Regularización de Tikhonov (RidgeCV y LassoCV)
 - Regularización por Norma Max (Max-Norm Regularization)
 - Dropout como Regularización
 - Parada temprana (*Early Stopping*)

REGRESIÓN LOGÍSTICA

- Regularización

- Elastic Net

- Combina las regularizaciones L1 y L2, incorporando ambas penalizaciones en la función de coste
 - Esto proporciona un equilibrio entre
 - Selección de características (como en *Lasso*)
 - Estabilidad de los coeficientes (como en *Ridge*)
 - En general, Elastic Net no es una técnica de regularización, sino un modelo de regresión lineal con una función de coste que incorpora penalizaciones L1 y L2

REGRESIÓN LOGÍSTICA

- Regularización

- Elastic Net

- Es decir, Elastic Net es una combinación de dos de los mejores enfoques de regresión lineal por “contracción”:
 - Regresión *lasso* (penalización L1)
 - Se ocupa de la selección de características de los coeficientes de regresión
 - Para ello, utiliza la contracción de los coeficientes de regresión hacia cero o igual a cero para reducir la aparición de variables predictoras
 - Regresión *ridge* (penalización L2)
 - Se ocupa de los problemas de alta multicolinealidad

REGRESIÓN LOGÍSTICA

- Regularización

- Elastic Net

- Función de coste utilizada:

$$L = \sum \left(y_i - \sum b_j x_j \right)^2 + \lambda_1 \sum |b_j| + \lambda_2 \sum b_j^2$$

- Más comúnmente, se suele utilizar (equivalente):

$$L = \sum \left(y_i - \sum b_j x_j \right)^2 + \alpha \left(\lambda \sum |b_j| + (1 - \lambda) \sum b_j^2 \right)$$


- donde λ es el ratio de LI y α es el nivel de penalización global

REGRESIÓN LOGÍSTICA

- Regularización
 - Elastic Net
 - Ayuda a producir un modelo ajustado e interpretable minimizando las variables innecesarias que no aparecen en el modelo final para mejorar la precisión de la predicción
 - Gestiona la multicolinealidad manteniendo o excluyendo del modelo ajustado las variables predictoras altamente correlacionadas

REGRESIÓN LOGÍSTICA

- Regularización
 - Elastic Net
 - Elastic Net (rojo) es una combinación de la regresión *ridge* (negro) y *lasso* (azul)



REGRESIÓN LOGÍSTICA

- Regularización
 - Elastic Net
 - Regresión lineal, *lasso* y *ridge* se pueden considerar casos especiales de Elastic Net
 - En 2014, se demostró que Elastic Net puede reducirse a una SVM lineal
 - La función de *loss* es fuertemente convexa y, por tanto, existe un mínimo único

REGRESIÓN LOGÍSTICA

- Regularización

- Regularización de Tikhonov

- Un problema de regresión lineal intenta encontrar un vector \mathbf{x} tal que

$$A\mathbf{x} = \mathbf{b}$$

- mediante la minimización de

$$\|A\mathbf{x} - \mathbf{b}\|_2^2$$

- $\|\cdot\|_2$: norma euclídea
 - Sin embargo, para hallar una solución que tenga unas propiedades específicas, se añade un término de regularización a la función a minimizar:

$$\|A\mathbf{x} - \mathbf{b}\|_2^2 + \|\Gamma\mathbf{x}\|_2^2$$

REGRESIÓN LOGÍSTICA

- Regularización
 - Regularización de Tikhonov
 - Si se escoge una matriz de Tikhonov Γ que sea un múltiplo escalar de la matriz identidad ($\Gamma = \alpha I$)
 - Se intentará encontrar soluciones con normas bajas
 - Esto es la regresión *ridge*
 - Es decir, la regularización L2 (*ridge*) es un caso particular de esta

REGRESIÓN LOGÍSTICA

- Regularización
 - Regularización por Norma Max (*Max-Norm Regularization*)
 - Idea principal:
 - Similar a las técnicas anteriores
 - Evitar que los parámetros tomen valores muy altos
 - Para que el modelo no se ajuste a ejemplos específicos del conjunto de entrenamiento
 - Técnica de regularización algo más agresiva que L1 y L2 a la hora de evitar el uso de pesos grandes
 - L1 y L2 → Añaden un término de penalización
 - «Desincentivan» el uso de valores grandes
 - *Max-Norm* → Restringe los valores, garantizando que su magnitud no supere un determinado valor umbral

REGRESIÓN LOGÍSTICA

- Regularización
 - Regularización por Norma Max (*Max-Norm Regularization*)
 - Por tanto, esta técnica se implementa imponiendo un límite superior a la magnitud del vector de parámetros
 - Esta magnitud suele ser medida con la norma L2
 - Pero podría ser con cualquier otra norma
 - Si la norma L2 del vector de coeficientes supera este límite, se escala el vector para que cumpla con el límite

REGRESIÓN LOGÍSTICA

- Regularización

- Regularización por Norma Max (*Max-Norm Regularization*)

- Esta técnica es particularmente útil en redes neuronales profundas
 - El control de la magnitud de los parámetros puede contribuir a un entrenamiento más estable y prevenir problemas de explosión del gradiente
 - También puede ayudar a mejorar la capacidad de generalización del modelo al limitar su complejidad

$$w = \begin{cases} w & \text{if } \|w\|_2 \leq r \\ r \frac{w}{\|w\|_2} & \text{otherwise.} \end{cases} \quad \|w\|_2 = \sqrt{w_1^2 + w_2^2 + \cdots + w_n^2}$$

REGRESIÓN LOGÍSTICA

- Regularización
 - *Dropout* como Regularización
 - Aunque generalmente se asocia con redes neuronales, el *dropout* también puede aplicarse a regresión logística y otros modelos
 - *Dropout* en RR.NN.AA.:
 - Desactivar aleatoriamente varias neuronas en cada ciclo (*epoch*) de entrenamiento

REGRESIÓN LOGÍSTICA

- Regularización

- *Dropout* como Regularización

- Aunque generalmente se asocia con redes neuronales, el *dropout* también puede aplicarse a regresión logística y otros modelos
 - *Dropout* en otros modelos:
 - Desactivar aleatoriamente un porcentaje de características (coeficientes) durante cada iteración de entrenamiento
 - Sólo es válido en modelos que se entrenan de forma iterativa, modificando los parámetros de un único modelo en cada iteración
 - Por ejemplo, en Computación Evolutiva no se podría utilizar
 - Es iterativo, pero cada individuo es un modelo en sí
 - No se modifica el mismo modelo en cada iteración

REGRESIÓN LOGÍSTICA

- Regularización

- Parada temprana (*early stopping*)

- Muy utilizado en RR.NN.AA., pero también puede ser utilizado en otros modelos
 - Detener el entrenamiento del modelo cuando el rendimiento en un conjunto de validación comienza a empeorar
 - Porque se considera que empieza a empeorar en funcionamiento con datos nuevos (validación)
 - Empieza a sobreajustar
 - Además, el modelo a devolver puede no ser el que se tiene en el momento de parar el entrenamiento
 - Puede ser el de un ciclo anterior: el de menor validación

REGRESIÓN LOGÍSTICA

- Regularización

- Parada temprana (*early stopping*)

- Esto puede ayudar a evitar que el modelo se ajuste demasiado a los datos de entrenamiento
 - Se intenta que el modelo «no desarrolle» su complejidad
 - Al igual que antes, sólo puede ser aplicado en modelos cuyo entrenamiento es iterativo
 - Para poder parar antes en una iteración temprana
 - Si se aplica en modelos entrenados en un proceso de evaluación de muchos modelos
 - Como en Computación Evolutiva
 - ¡Se podría sobreajustar al conjunto de validación!

REGRESIÓN LOGÍSTICA

- Ventajas:
 - Intrínsecamente interpretable
 - Se puede entender cómo las características afectan las probabilidades de clasificación
 - Es decir, los coeficientes b_1, b_2, \dots, b_n en la ecuación del modelo tienen significado
 - Un coeficiente positivo indica que un aumento en la característica incrementa la probabilidad de pertenecer a la clase 1
 - Un coeficiente negativo indica lo contrario.
 - Entrenamiento eficiente
 - Basado en gradiente descendente

REGRESIÓN LOGÍSTICA

- Desventajas:
 - El *log-odds* se basa en un modelo lineal
 - Capacidad de separar datos muy limitada
 - Hiperplano
 - Muchos problemas del mundo real requieren de regiones de separación más complejas

REGRESIÓN LOGÍSTICA

- Conclusiones
 - Técnica de clasificación que combina la regresión lineal con una función sigmoide para calcular la probabilidad de pertenencia a la clase positiva
 - Regresión lineal → realiza una separación lineal
 - Se puede entrenar mediante gradiente descendente
 - Necesario definir su propia función de coste
 - Expresión final idéntica a la Regla Delta
 - Aplicación de técnicas de regularización
 - Nuevos modelos de regresión
 - Regresión *lasso*, *ridge*, *elastic net*